

Expandiendo Stable Diffusion

Proyecto INVERSO

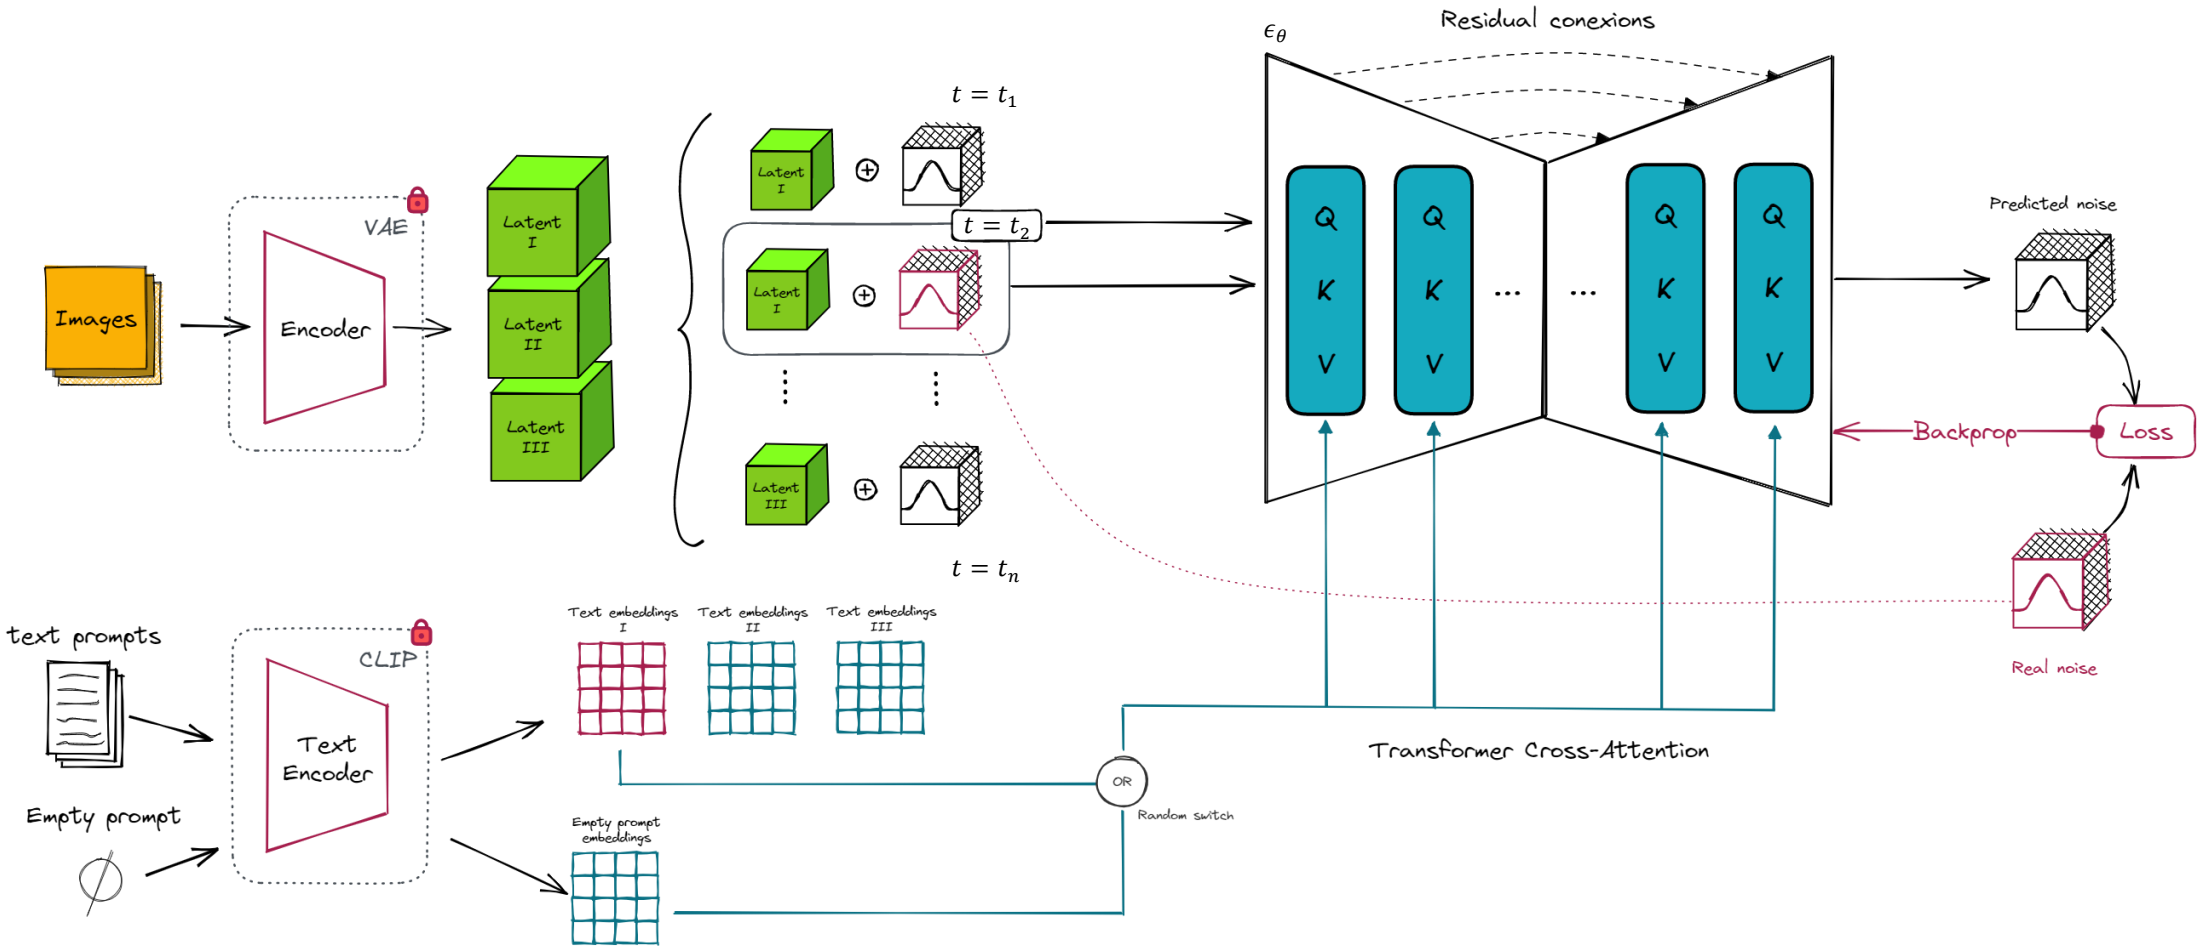
Métodos de re-entrenamiento y adaptación a nuevos dominios

Adrian Mikel Maiza Coupin

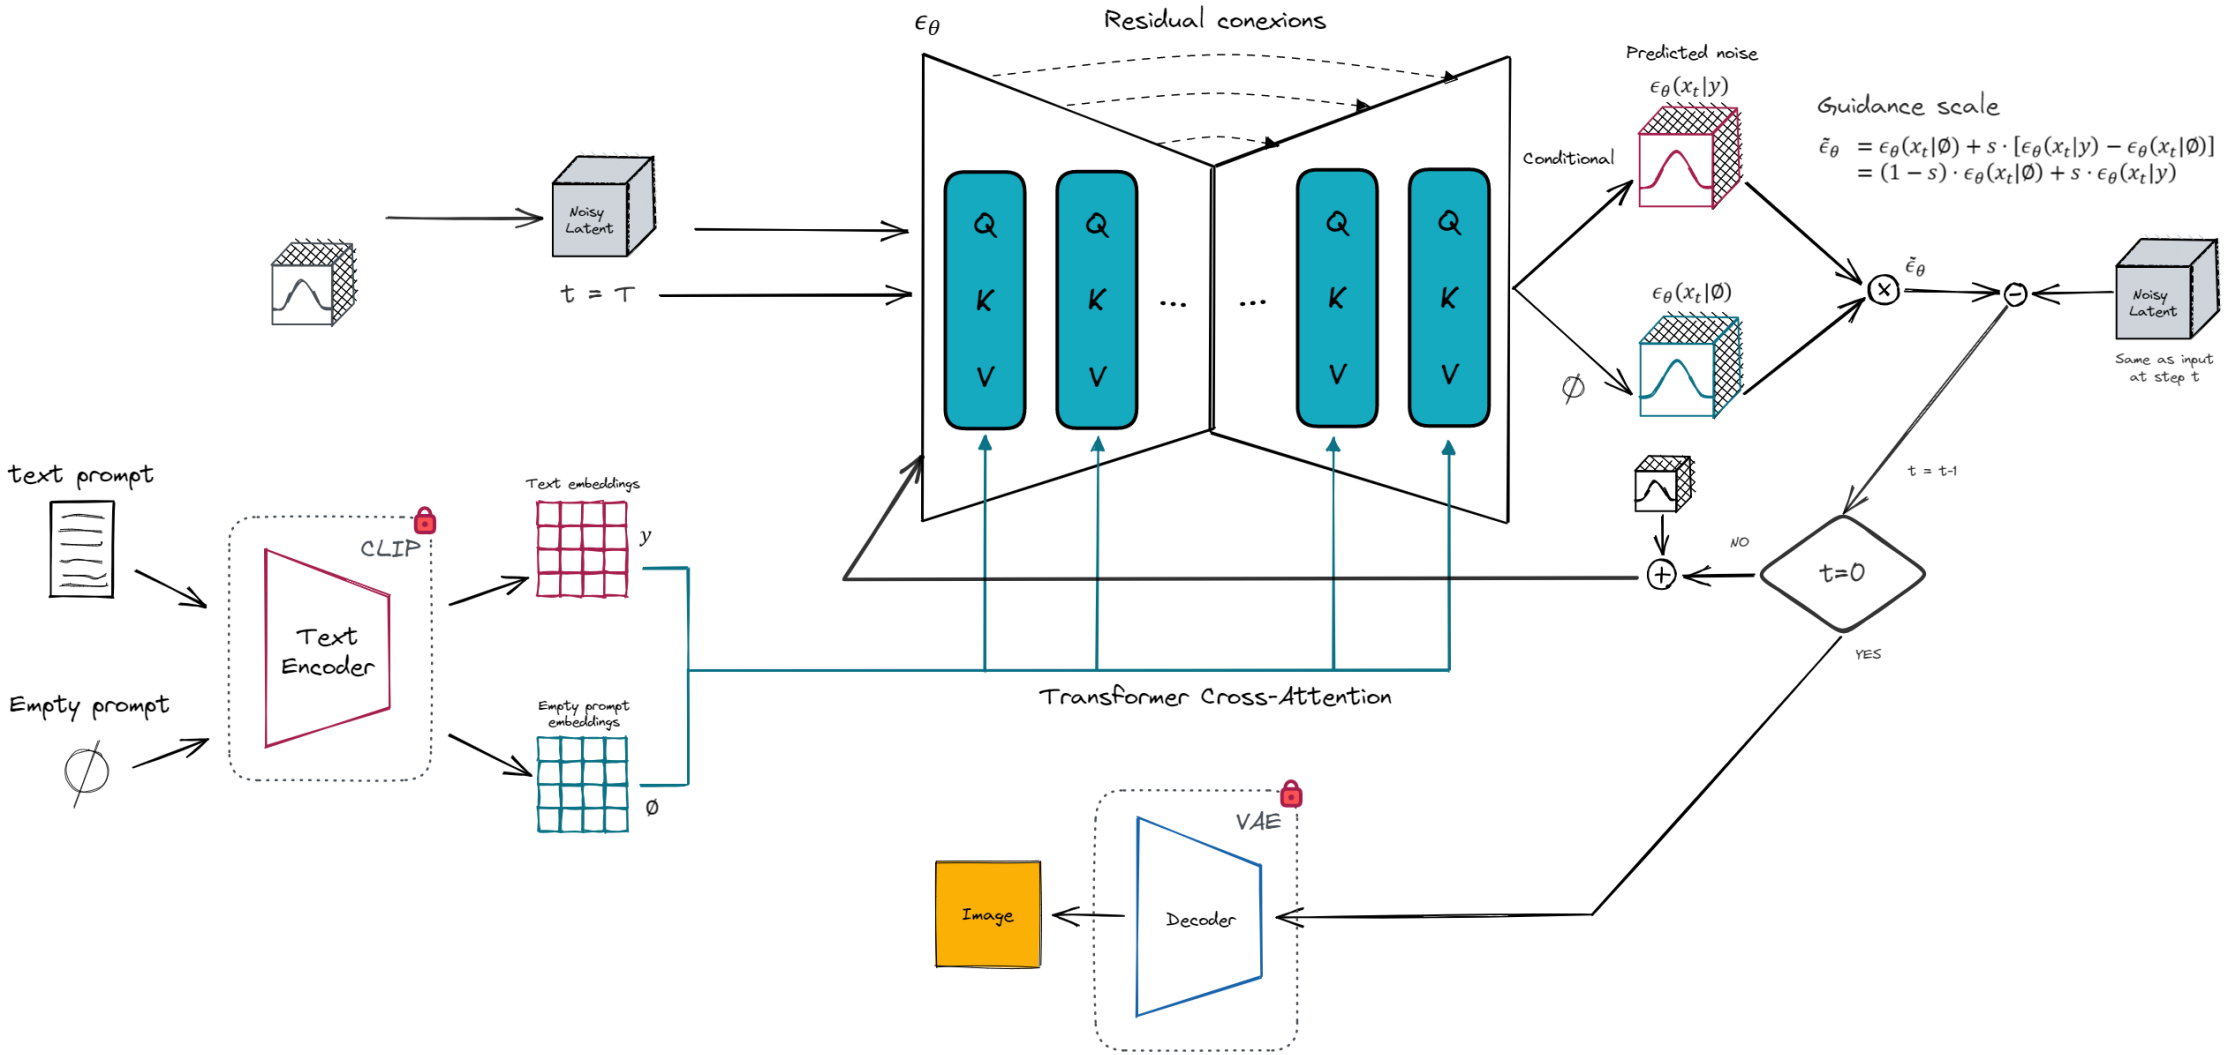
upna
Universidad Pública de Navarra
Nafarroako Unibertsitate Publikoa

01 Recap: Entrenamiento SD

upna

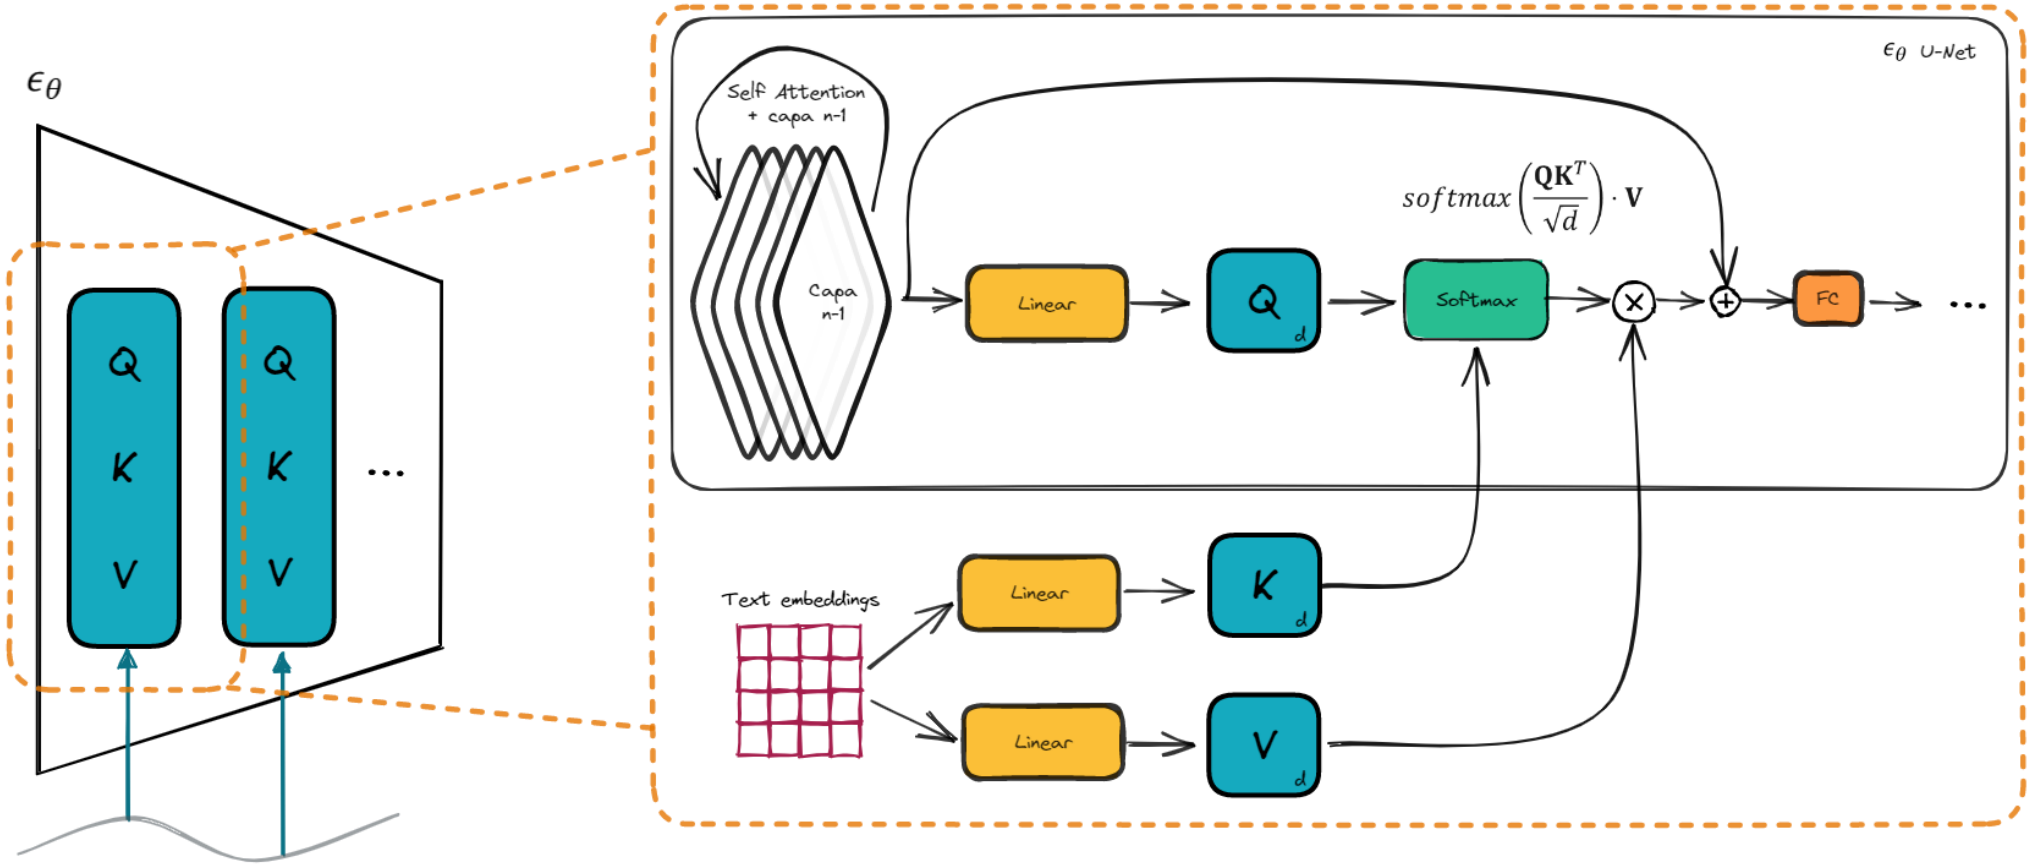


01 Recap: Inferencia SD



01 Recap: Inferencia SD

upna



02 Expandiendo el conocimiento de Stable Diffusion

upna

¿Que métodos existen a día de hoy?

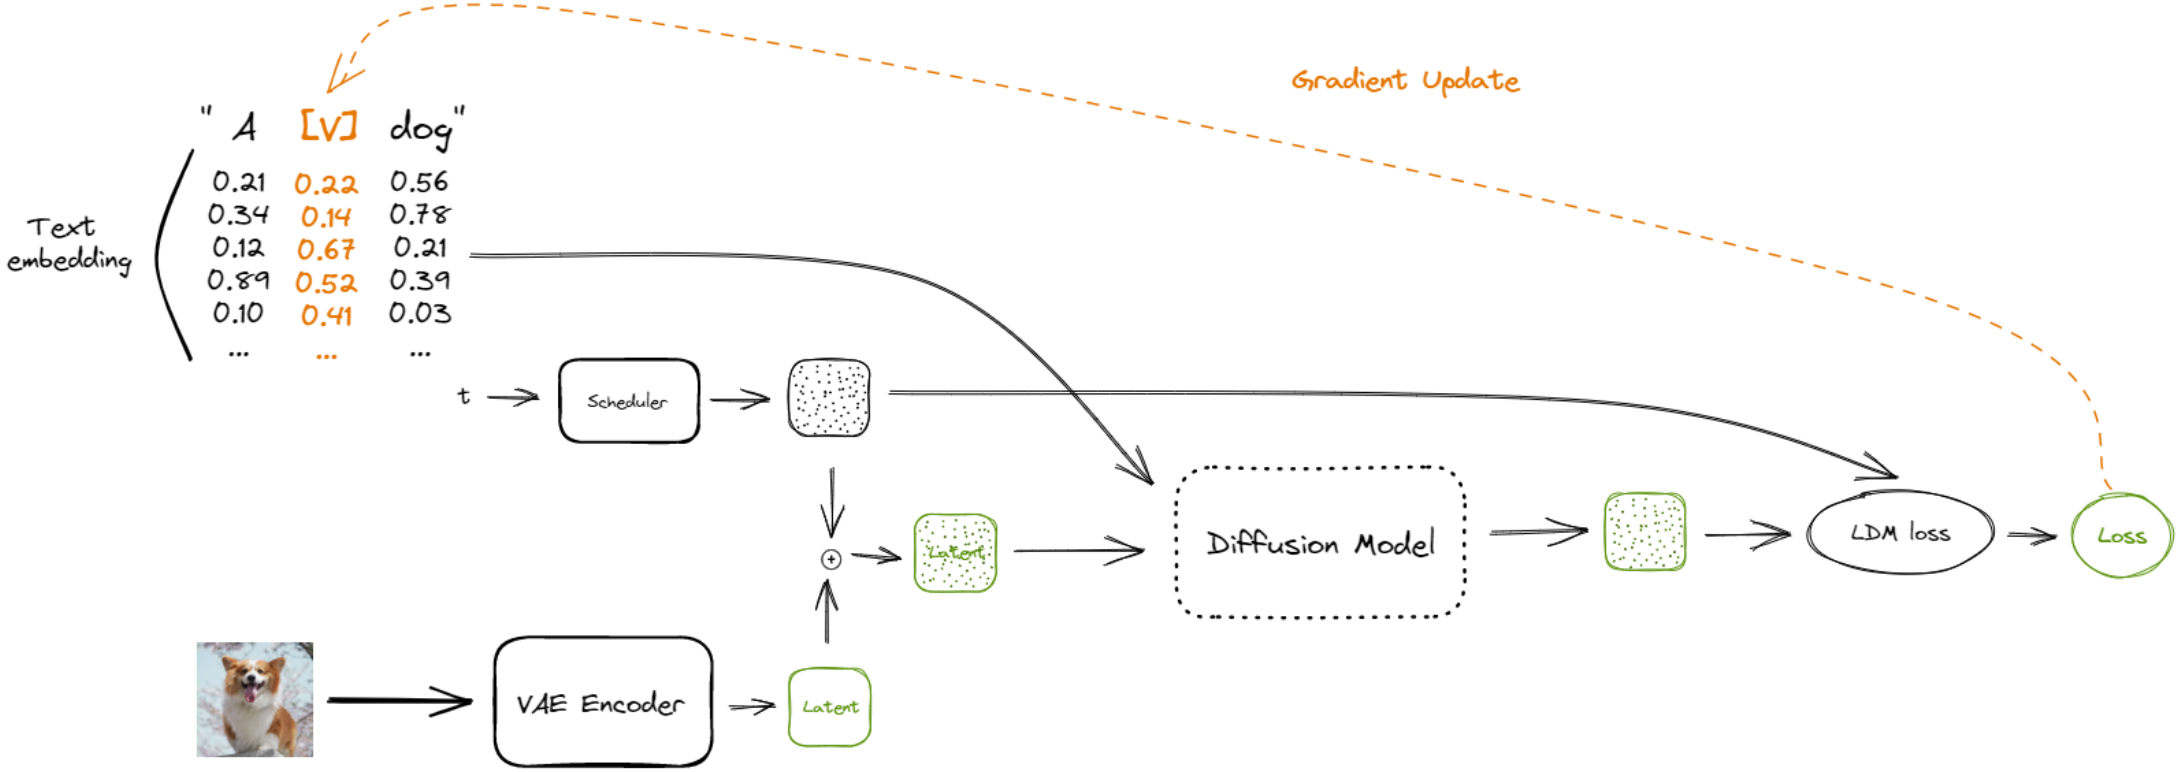
Al ser un tema con mucho auge en los últimos meses, el conjunto de métodos para "reentrenar" el modelo de **Stable Diffusion**, haciendo que éste **genere datos de nuevos dominios**, es bastante amplio. La mayoría de estos métodos pretenden añadir nuevo conocimiento al modelo, expandiendo así la variedad de imágenes que puede generar. Es decir, le enseñan **nuevos conceptos** como "*fotos de mi gata Luna*", "*diseños de personajes con el estilo de nuestro dibujante*", "*edificios diseñados por mí*" o "*fotos de la tía Pili*" que éste, de base, **no entiende**.

Por ahora, identificamos ***cuatro*** métodos para conseguir esto:

Textual Inversion | **DreamBooth** | **Custom Diffusion** | **LoRA**

02 Textual Inversion

upna



02 Dreambooth

upna

"A [identifier] [class noun]"

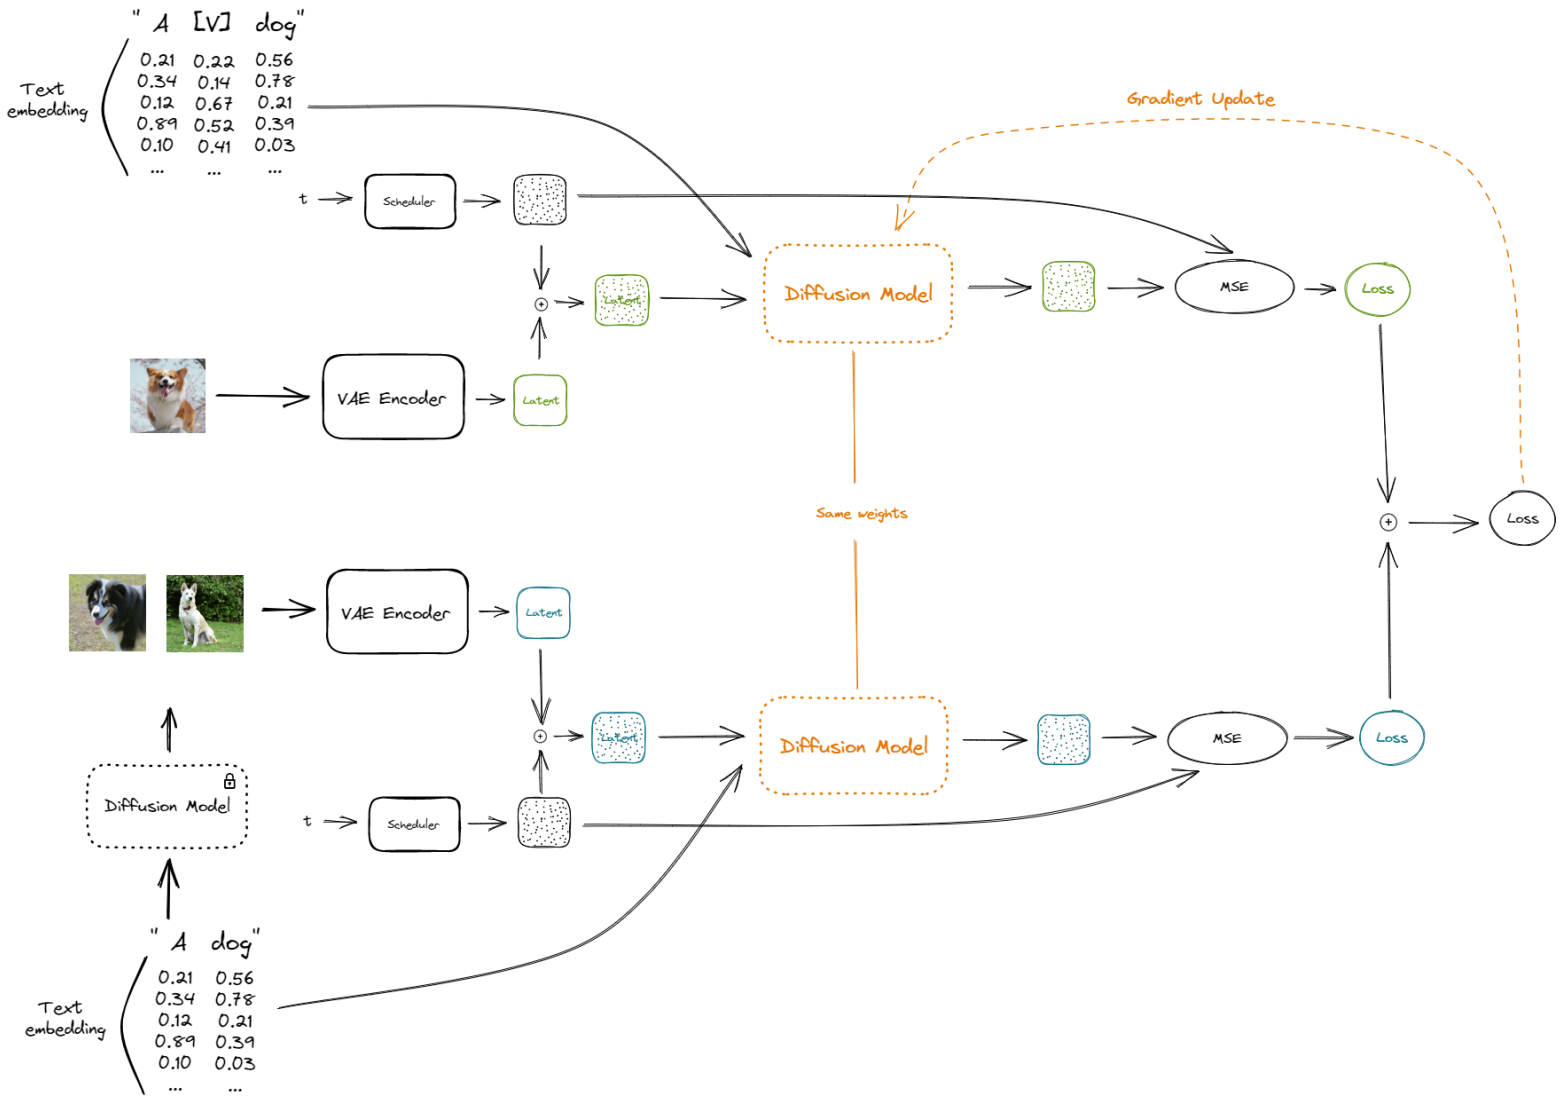
1) Utilizar una palabra existente como identificador (único/especial) ->
   Aumenta el tiempo de entrenamiento y disminuye el rendimiento

2) Generar un identificador raro mezclando letras/números aleatorios (xxy5st) ->
   El tokenizador podría tokenizar cada letra por separado

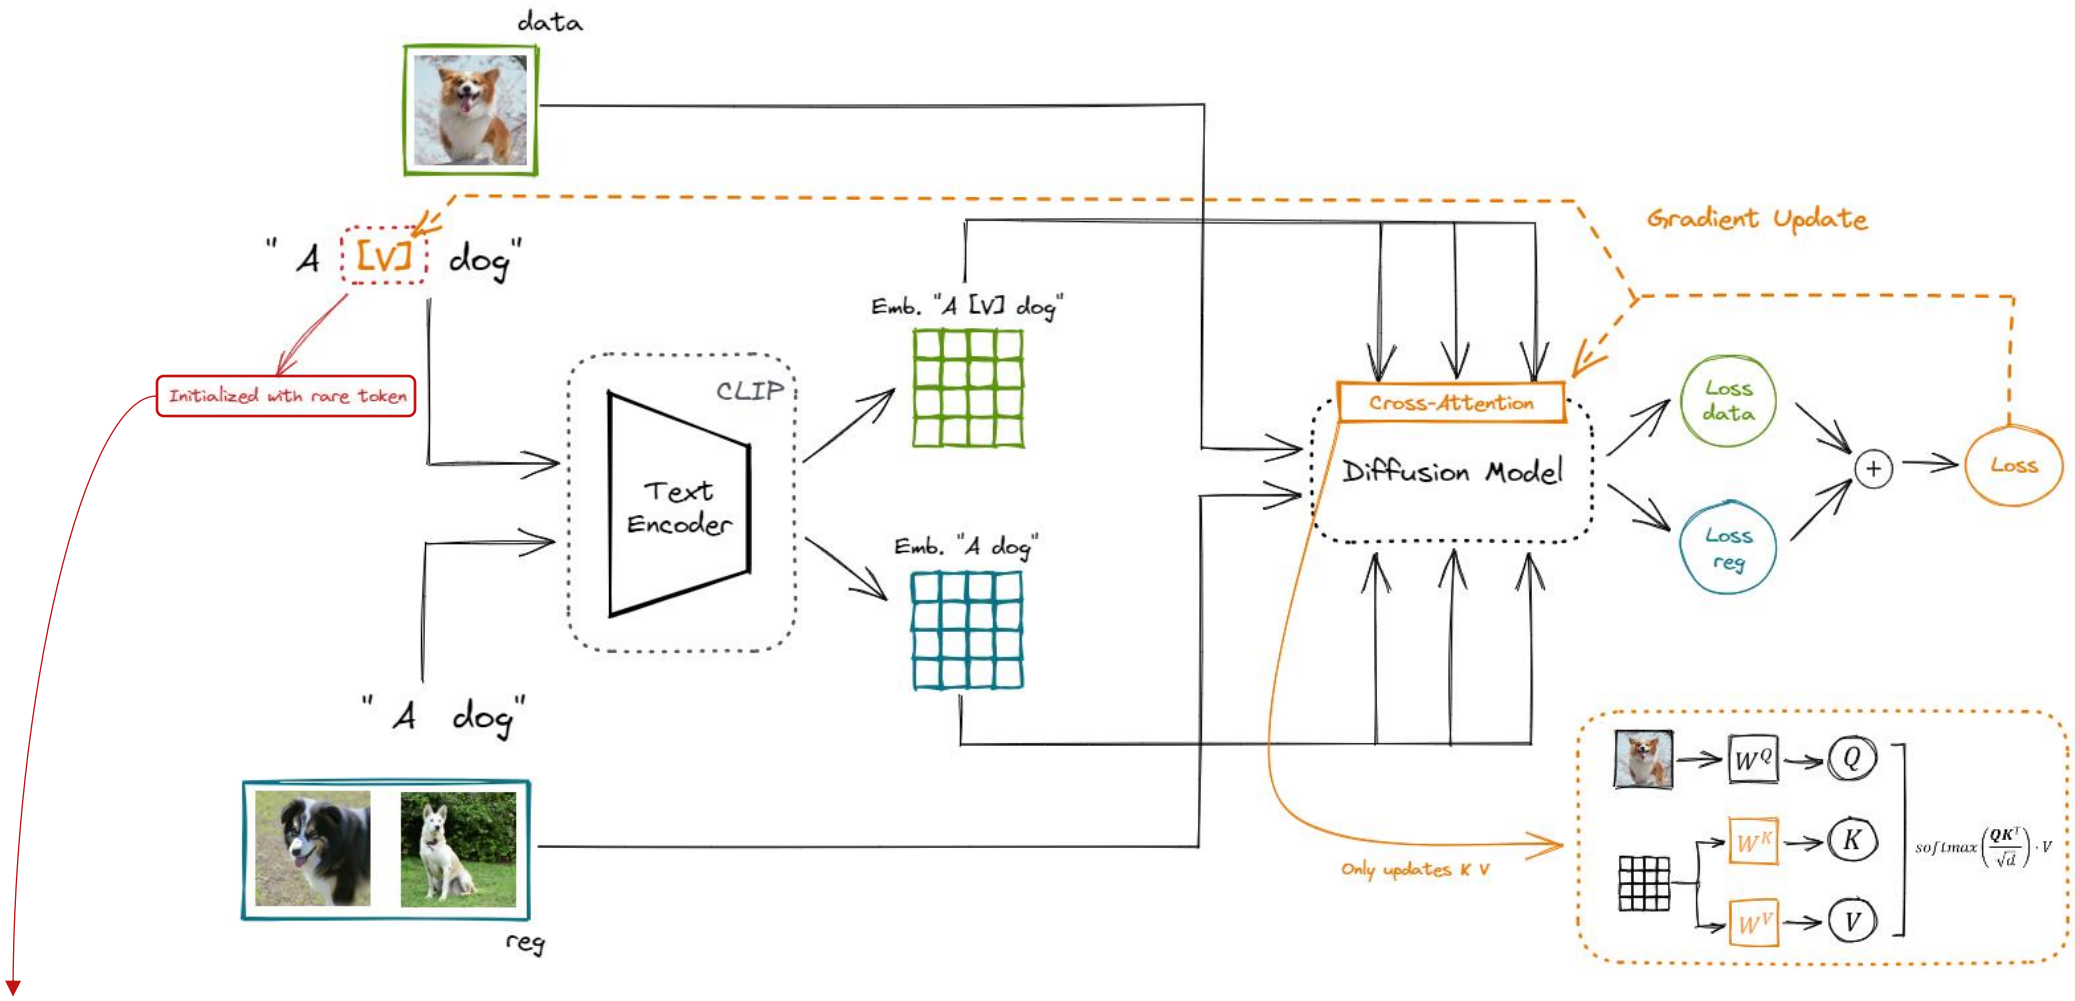
3) Encontrar un token raro en el vocabulario y luego invertirlos en el espacio de texto
   Al final se buscan palabras con longitud 3

02 Dreambooth

upna



02 Custom Diffusion



Conseguimos el "token raro" seleccionando un $V^* \in P_{200k}$, donde $P_{200k} \subseteq \text{LAION}_{400\text{M}}$.

Este V^* debe cumplir $5 \leq count(V^*) \leq 10$ y, a su vez, V^* no debe ser sub-token de ningún otro token

02 LoRA

upna

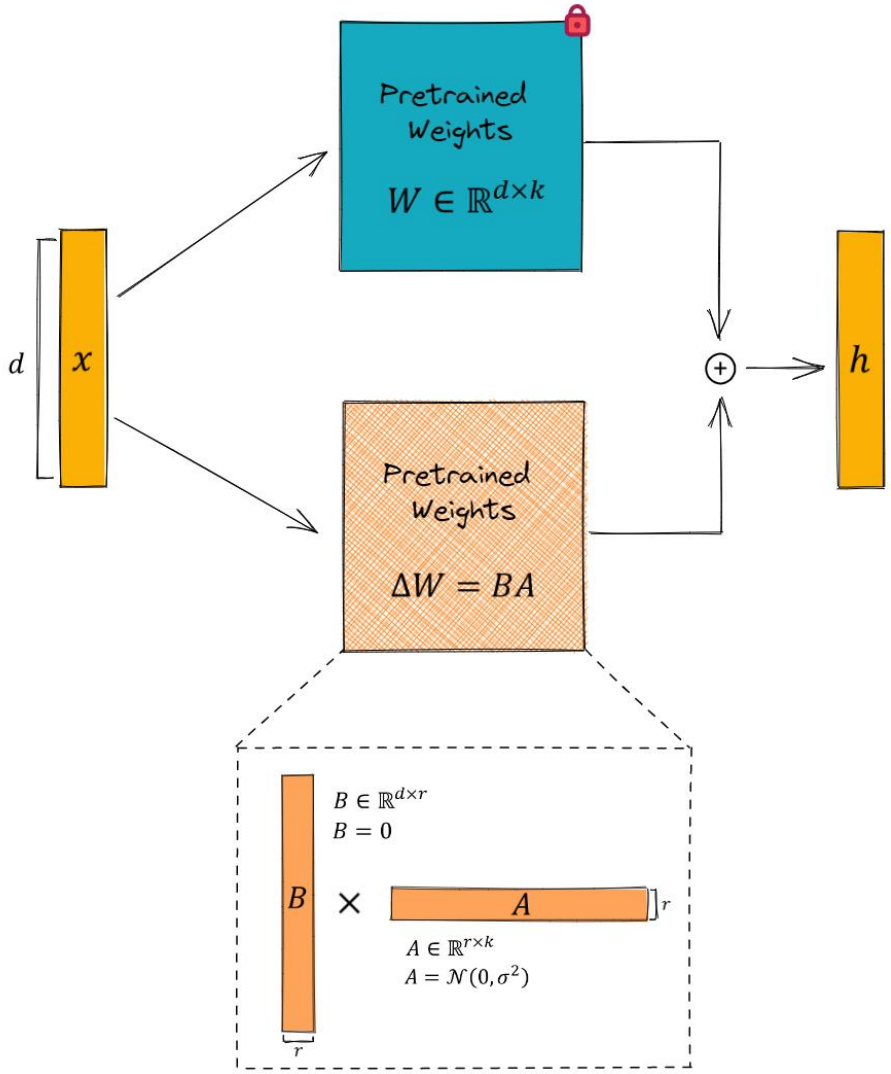
¿Qué es exactamente LoRA?

LoRA, acrónimo de "**Lo**w-**R**ank **A**daptation", es una técnica de *finetuning* que, aunque está diseñada para todo tipo de modelos, en el artículo la proponen para los *"Large Language Models"* (LLM).

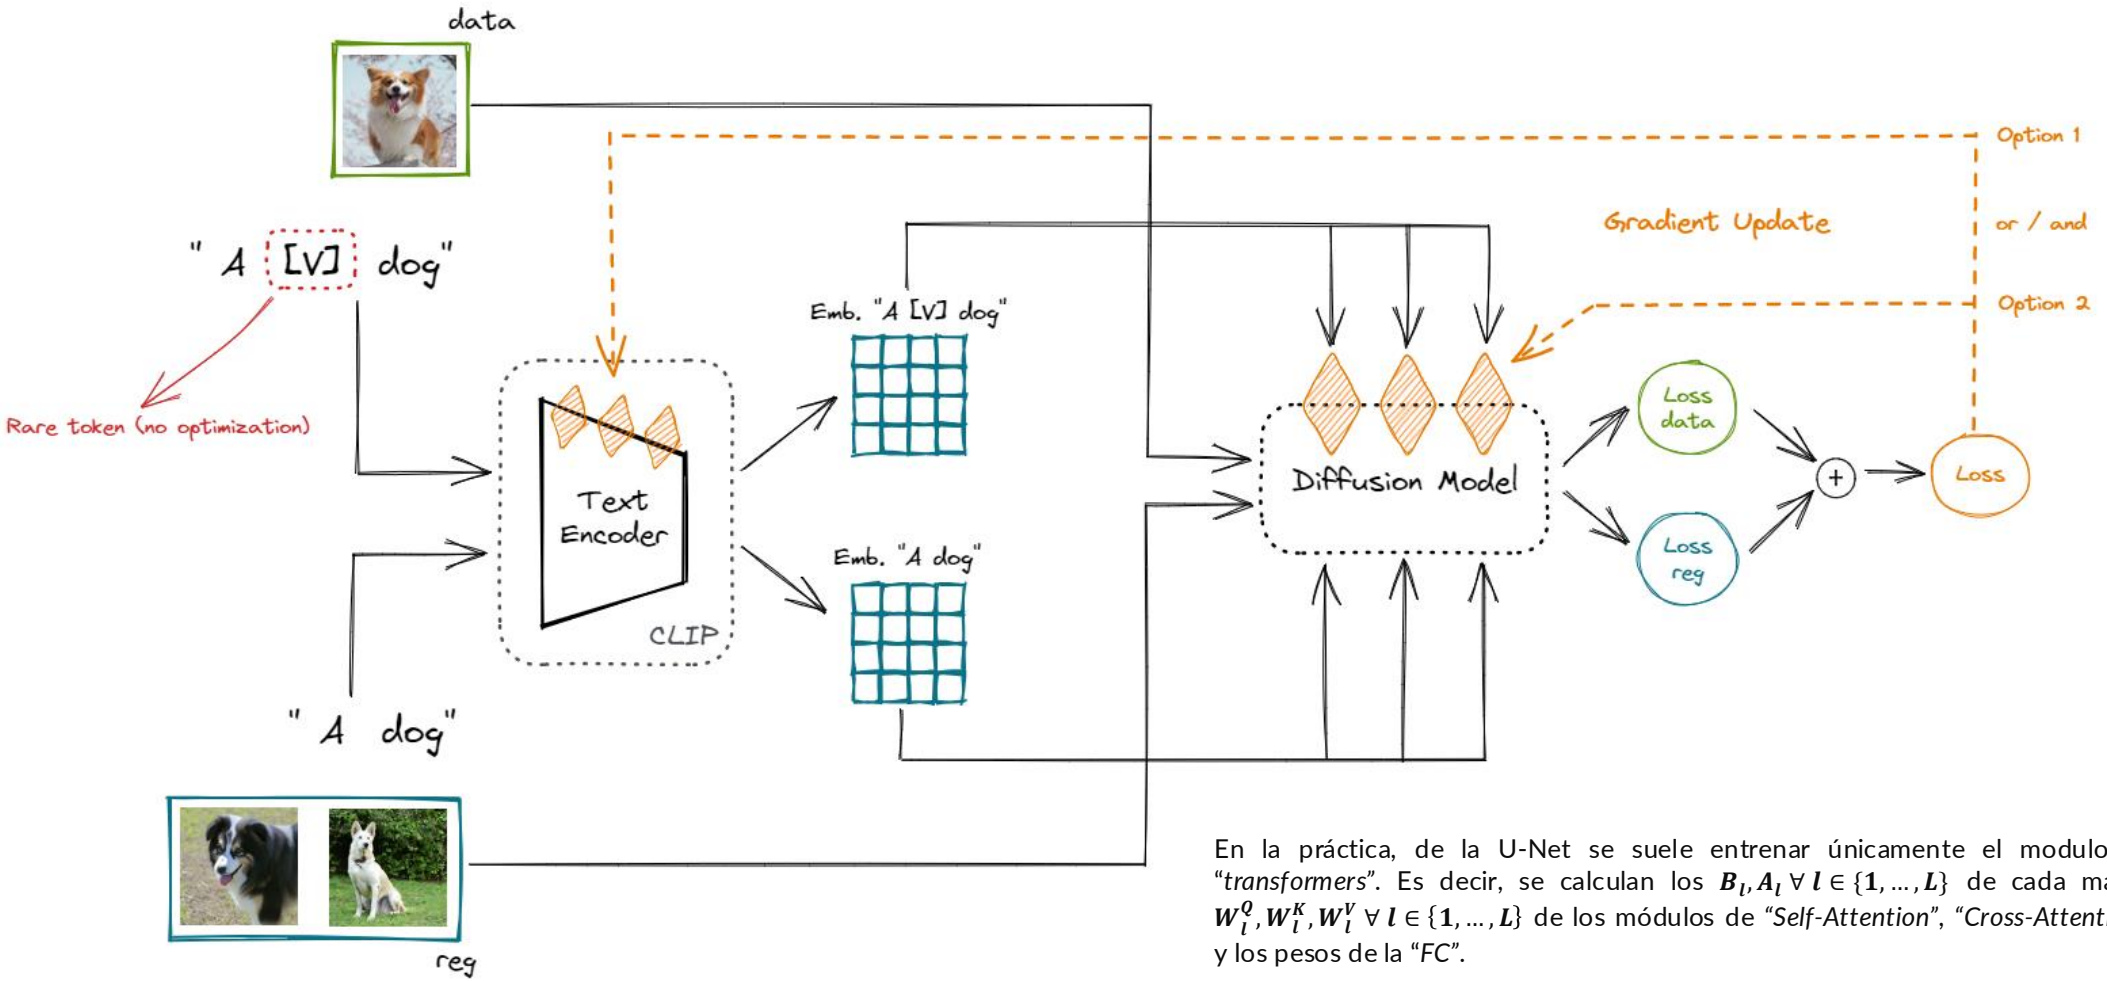
La base de esta técnica reside en la descomposición de la nueva matriz de pesos ΔW en dos sub-matrices B y A que tienen un rango r mucho menor. A la hora de entrenar, únicamente se aprenden los valores de B y A, haciendo que aplicar nuevos pesos sea menos costoso en tiempo y memoria.

$$h = W'x = Wx + \Delta Wx = Wx + BAx$$

$$W \in \mathbb{R}^{d\times k}, B \in \mathbb{R}^{d\times r}, A \in \mathbb{R}^{r\times k}, r \ll \min(d,k)$$



02 Dreambooth con LoRA



En la práctica, de la U-Net se suele entrenar únicamente el modulo de "*transformers*". Es decir, se calculan los $\boldsymbol{B_l, A_l}\ \forall\ \boldsymbol{l} \in \{\mathbf{1}, \ldots, \boldsymbol{L}\}$ de cada matriz $\boldsymbol{W_l^Q, W_l^K, W_l^V}\ \forall\ \boldsymbol{l} \in \{\mathbf{1}, \ldots, \boldsymbol{L}\}$ de los módulos de "*Self-Attention*", "*Cross-Attention*", y los pesos de la "*FC*".