# Generando rostros humanos etiquetados mediante GANs para reconocimiento de emociones

**Autor:** Adrian Mikel Maiza Coupin

**Director**: Mikel Galar Idoate

## Introducción

En este TFG estudiamos la viabilidad de utilizar **datos sintéticos**, generados mediante **Redes Generativas Adversarias** (GAN), para **entrenar** modelos de **reconocimiento de expresiones faciales**.

Para ello, comparamos entre diferentes técnicas de **condicionado** de GANs para generar datasets “a la carta”.



## Objetivos

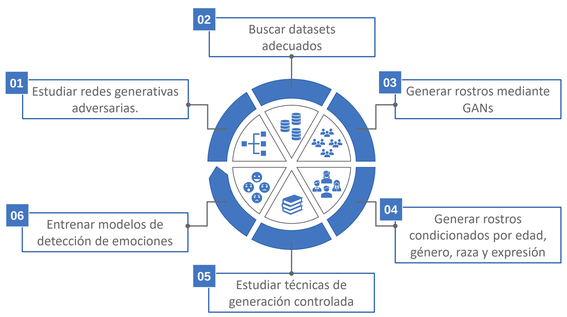



*Figura 1. Objetivos del Trabajo Fin de Grado.*

## Antecedentes

Para decidir cuál es el mejor modelo, en este trabajo utilizamos **métricas** acordes a las GAN como la Distancia de Incecpión de Frechét (**FID**), **Precision**, **Recall** y su media harmónica $F_1$.

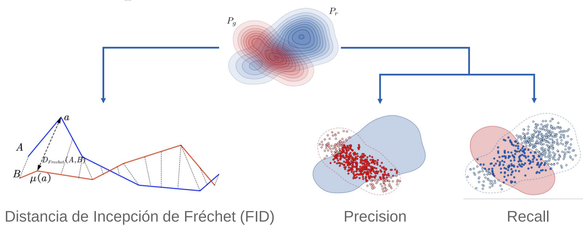



*Figura 2. Métricas utilizadas para comparar modelos GAN.*

## Propuesta

Proponemos utilizar el *dataset* **AffectNet** [1] etiquetado demográficamente mediante **FairFace** [2,3] y entrenar un modelo **condicionado** de **StyleGAN2** [4].

**Método:** Condicionar StyleGAN2

- Generador
  - Condicionado por **mapeo** (■ en Figura 3)
  - Condicionado por **estilo** (■ en Figura 3)
- Discriminador
  - Condicionado de **salida** (■ en Figura 3)

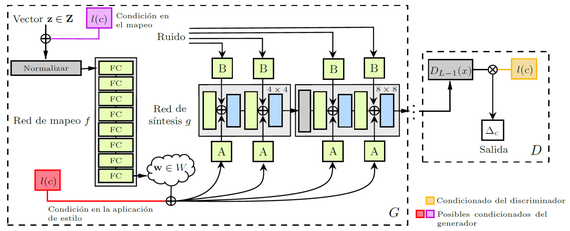



*Figura 3. Arquitectura propuesta de StyleGAN2 condicionado.*

## Resultados

Después de probar varias configuraciones, comparamos las métricas de **Precision** y **Recall** de varios *checkpoints*. Para el mejor valor de la frontera de Pareto superior del valor de $F_1$, calculamos el **FID** (véase Figura 4).

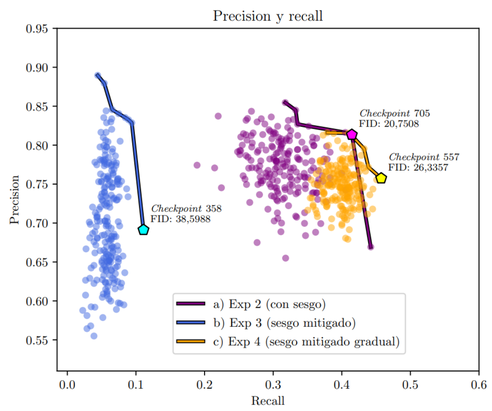



*Figura 4. Gráfica de métricas de varios checkpoints en diferentes experimentos.*

La Tabla 1 muestra las **métricas** y desviaciones estándar del **mejor modelo** por experimento.

| Experimento | FID ↓ | Precision ↑ | Recall ↑ | $F_1$ ↑ |
|---|---|---|---|---|
| 2 (con sesgo) | $\mathbf{20{,}7508 \pm 0{,}5631}$ | $\mathbf{0{,}8134 \pm 0{,}0052}$ | $0{,}4146 \pm 0{,}0072$ | $0{,}5492 \pm 0{,}0057$ |
| 3 (sin sesgo) | $38{,}5988 \pm 0{,}8482$ | $0{,}6912 \pm 0{,}0099$ | $0{,}1109 \pm 0{,}0032$ | $0{,}1912 \pm 0{,}0051$ |
| 4 (con medio sesgo) | $26{,}3357 \pm 0{,}2772$ | $0{,}7574 \pm 0{,}0058$ | $\mathbf{0{,}4574 \pm 0{,}0087}$ | $\mathbf{0{,}5704 \pm 0{,}0081}$ |

*Tabla 1. Métricas de los mejores checkpoints para cada experimento.*

Con los modelos del experimento **2** y **4**, con mejores **FID** y $F_1$ respectivamente, se generan matrices de imágenes en las que se **demuestran** sus **capacidades** de **generación condicionada** (véase Figura 5).

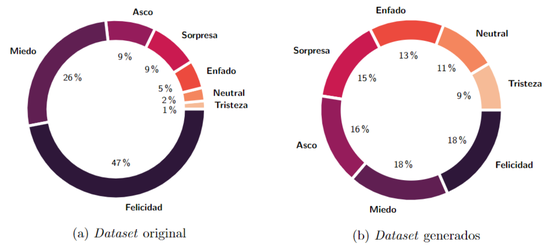



(a) Experimento 2 (b) Experimento 4

*Figura 5. Ejemplo de la capacidad de generación condicionada de los modelos.*

## Comparativa

Con los mejores modelos listos, abordamos el objetivo principal: **entrenar modelos de reconocimiento de emociones faciales**. Generamos un dataset **balanceado** (véase Figura 6) y entrenamos modelos **ResNet50** [5] con datos **reales** y **sintéticos**.




(a) *Dataset* original (b) *Dataset* generados

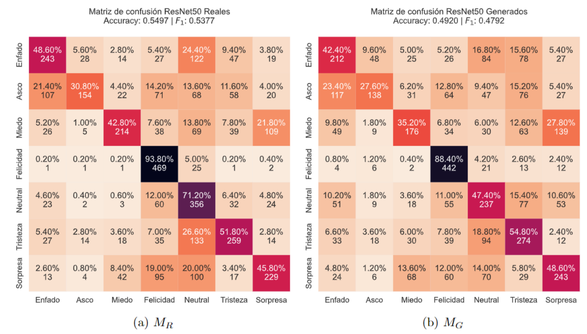
*Figura 6. Balance de número de instancias por clase de cada dataset.*

Después de entrenar los modelos **ResNet50**, comparamos diferentes configuraciones usando el **mismo conjunto** de **test**. En la Tabla 2 se muestran los valores de las métricas.

| Modelo | Balanceo | Accuracy ↑ | Precisión ↑ | Recall ↑ | $F_1$ ↑ |
|---|---|---|---|---|---|
| Datos reales | | 0.5497 | 0.5847 | 0.5497 | 0.5377 |
| Datos Experimento 2 | | 0.4769 | **0.4964** | 0.4769 | 0.4752 |
| | ✓ | 0.4834 | 0.4924 | 0.4834 | 0.4748 |
| Datos Experimento 4 | | 0.4771 | 0.4903 | 0.4771 | 0.4777 |
| | ✓ | **0.4920** | 0.4955 | **0.4920** | **0.4792** |

*Tabla 2. Resultados de modelos ResNet50 con cada configuración.*

Como el **mejor modelo** entrenado con datos generados es el del **experimento 4**, comparamos su **matriz de confusión** con la del modelo entrenado con datos reales (véase Figura 7).




(a) $M_R$ (b) $M_G$

*Figura 7. Matrices de confusión de los mejores modelos ResNet50 entrenados.*

## Conclusión

1. Viabilidad de uso de datos sintéticos. 👍
2. Resultados mejorables. 👎
3. Posibilidad de prescindir de datasets sujetos a RGPD. 👍
4. Oportunidades de desarrollo e investigación. 👍

## Referencias

[1] Ali Mollahosseini, Behzad Hasani y Mohammad H. Mahoor. “*AffectNet: A Database for Facial Expression, Valence, and Arousal Computing in the Wild*”. En: IEEE Transactions on Affective Computing 10.1 (ago. de 2017)

[2] Iris Dominguez-Catena, Daniel Paternain y Mikel Galar. “*Assesing Demographic Bias Transfer from Dataset to Model: A case Study in Facial Expression Recognition*” (mayo de 2022)

[3] Kimmo Kärkkäinen y Jungseock Joo UCLA. “*FairFace: Face Attribute Dataset for Balanced Race, Gender, and Age*” (ago. de 2019)

[4] Tero Karras et al. “Analyzing and Improving the Image Quality of StyleGAN”. En: *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition* (dic. de 2019)

[5] Kaiming He et al. “*Deep Residual Learning for Image Recognition*”. En: *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition* (dic. de 2015)

Cátedra de Ciencias de la Computación e Inteligencia Artificial

upna tracasa instrumental

Adrian Maiza — **adrian.maiza@unavarra.es**

Escuela Técnica Superior de Ingeniería Industrial, Informática y de Telecomunicación (ETSIIIT)